

Лабораторная работа №1

Тема: тестирование генератора псевдослучайных чисел

Задание

- Создать генератор последовательности равномерно распределенных случайных чисел на основе смешанного алгоритма Лемера. Подобрать параметры генератора, который дает максимальный период.
- Для сгенерированной выборки построить гистограмму (20+ интервалов).
- Используя критерий хи-квадрат и КС, подтвердить гипотезу о равномерности последовательности.
- Отобразить результаты графически.
- Сделать вывод о согласованности аналитических расчетов и визуализации.

Optional

Реализовать и протестировать генератор

- “усеченного” нормального распределения
- или треугольного распределения.

Алгоритм Лемера

Исходные данные:

- x_0 – начальное значение ($x_0 \in 0$);
- a – множитель ($a > 0$);
- c – приращение ($c \neq 0$);
- m – модуль ($m > a$, $m > c$, $m > x_0$).

Тогда искомая последовательность псевдослучайных чисел получается из соотношения:

$$x_{n+1} = (a * x_n + c) \% m, n \geq 0. \quad (1)$$

Она называется линейной конгруэнтной последовательностью.

Для обозначения линейных конгруэнтных датчиков с $c=0$ и $c \neq 0$ применяются соответственно термины мультипликативный и смешанный метод.

Равномерно распределенная на $[0; 1]$ последовательность псевдослучайных чисел ($u_0, u_1, \dots, u_n, \dots$) получается из соотношения $u_n = x_n / m$ (или $u_n = x_n m^{-1}$, что более быстро выполняется компьютером).

Достаточное условие периода максимальной длины

Чтобы получить период максимальной длины m , множитель a и приращение c в линейном конгруэнтном датчике должны удовлетворять следующим условиям:

- c и m – взаимно простые числа;
- $b=a-1$ кратно p для любого простого p , являющегося делителем m ;
- b кратно 4, если m кратно 4.

Универсальные тесты для анализа случайных последовательностей

Критерий χ². Предположим, что все возможные результаты испытаний разделены на k категорий. Проводится n независимых испытаний (исход каждого испытания не влияет на исход остальных). Пусть p_s – вероятность того, что результат испытания попадет в категорию s , и пусть Y_s – число испытаний, которые действительно попали в категорию s . Сформируем статистику:

$$V = \sum_{s=1}^k \frac{(Y_s - np_s)^2}{np_s} \quad (2)$$

Формулу (3) можно преобразовать к виду, более удобному для вычислений:

$$V = \frac{1}{n} \sum_{s=1}^k \left(\frac{Y_s^2}{p_s} \right) - n \quad (3)$$

Затем V сравнивается с числом из таблицы для распределения χ^2 при количестве степеней свободы $k-1$. Если V меньше значения, соответствующего $p=0.99$, или больше значения, соответствующего $p=0.01$, то результаты бракуются как недостаточно случайные. Если p лежит между 0.99 и 0.95 или между 0.05 и 0.01, то результаты считаются "подозрительными". При значениях p , заключенных между 0.95 и 0.90 или 0.10 и 0.05,

результаты "слегка подозрительны". Часто с помощью критерия χ^2 проверяют по крайней мере три разные части исследуемого ряда чисел. Если не менее двух раз из трех результаты оказываются подозрительными, числа отбрасываются как недостаточно случайные.

Возникает вопрос о длине n последовательности случайных чисел, которую необходимо выбрать для данного теста. Теоретические расчеты показывают, что достоверные оценки получаются в том случае, когда в каждую из категорий попали не менее 5 испытаний, т.е. выполняется условие $Y_s > 4$, $s=1..k$.

Критерий Колмогорова–Смирнова (КС–критерий). Критерий χ^2 применяется в тех случаях, когда результаты испытаний разделяются на конечное число k категорий. Однако часто случайные величины могут принимать бесконечно много значений. В теории вероятностей и математической статистике непрерывные случайные величины описываются с помощью функции распределения:

$$F(x) = p\{X \leq x\} \quad (4)$$

Используя значения x_1, x_2, \dots, x_n случайной величины X , можно построить эмпирическую функцию распределения

$$F(x) = \frac{1}{n} \sum_{i=1}^n k(x_i), \quad (5)$$

где

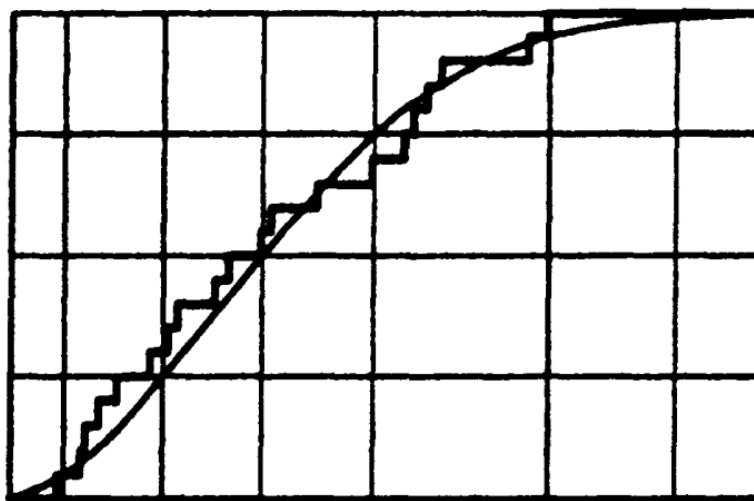
$$k(x) = \begin{cases} 1, & \text{если } X \leq x \\ 0, & \text{в противном случае} \end{cases}$$


Рис. Пример теоретической и эмпирической функций распределения

При увеличении n функции $F_n(x)$ должны все более точно аппроксимировать $F(x)$. КС-критерий можно использовать в тех случаях, когда $F(x)$ не имеет скачков, и он должен указать, насколько маловероятны большие расхождения между $F_n(x)$ и $F(x)$. Для этого используются следующие статистики:

$$\begin{aligned} K_n^+ &= \sqrt{n} \max_{-\infty < x < +\infty} (F_n(x) - F(x)) \\ K_n^- &= \sqrt{n} \max_{-\infty < x < +\infty} (F(x) - F_n(x)) \end{aligned} \quad (6)$$

K_n^+ показывает, каково максимальное отклонение для случая $F_n > F$, а K_n^- для $F_n < F$. Множитель \sqrt{n} нормирует статистики (7) таким образом, чтобы стандартное отклонение не зависело от n . Далее, как и в случае критерия χ^2 , сравнивают значения (7) с табличными и определяют, имеют ли они высокую или низкую значимость.

Формулы (7) не годятся для машинных расчетов, так как требуется отыскать максимальное среди бесконечного множества чисел. Однако, учитывая, что $F(x)$ неубывающая функция, а $F_n(x)$ имеет конечное число скачков, можно определить статистики (7) с помощью следующего алгоритма.

1. Определяются выборочные значения x_1, x_2, \dots, x_n .
2. Значения x_i располагаются в порядке возрастания так, чтобы $x_1 \leq x_2 \leq \dots \leq x_n$.
3. Статистики (7) вычисляются по следующим формулам:

$$\begin{aligned}
 K_n^+ &= \sqrt{n} \max_{1 \leq j \leq n} \left(\frac{j}{n} - F(x_j) \right) \\
 K_n^- &= \sqrt{n} \max_{1 \leq j \leq n} \left(F(x_j) - \frac{j-1}{n} \right)
 \end{aligned} \tag{7}$$

Критические значения КС-критерия определяются формулой $a - b / \sqrt{n}$.

p	0.99	0.95	0.75	0.5	0.25	0.05	0.01
a	0.0709	0.1601	0.3793	0.5887	0.8326	1.2239	1.5174
b	0.15	0.14	0.15	0.15	0.16	0.17	0.2

Отображение результатов

Опция 1. Инструменты табличного процессора.

Опция 2. Библиотека matplotlib из Python.

Пример скрипта приведен ниже.

```
import matplotlib.pyplot as plt

if __name__ == '__main__':
    random_numbers = [
        0.7619, 0.0612, 0.2, 0.7483, 0.0612, 0.7143, 0.415, 0.9,
        0.7143, 0.0544, 0.0816, 0.1633, 0.619, 0.619, 0.1973, 0.51
    ]
    plt.hist(random_numbers)
    plt.show()
```

Deadline 4.10 23:59

Структура отчета

Код датчика

Результаты трех прогонов для критерия $|2|$:

- гистограмма
- значения V и p

Результаты трех прогонов для КС-критерия

- графики теоретического и эмпирического распределений
- значения K^+ , K^- , p-отрезка в который попадают.

Артефакты для СЭО

- отчет
- архив с кодами для тестирования датчиков